

Jerarquías y dependencias entre hiperparámetros CART

Índice

Jerarquías y dependencias entre hiperparámetros CART	1
Supuestos y consideraciones	1
Estado de la información	2
Contradicciones y precisiones previas	2
Notación	2
Formalización de la factibilidad local	2
Regímenes de dominancia entre <code>minspl</code> y <code>minbucket</code>	3
Cota de profundidad factible	5
Restricciones para conservar una profundidad objetivo	5
Número de hojas y profundidad balanceada	6
Jerarquía de hiperparámetros con N chico	7
Jerarquía de hiperparámetros con N grande	8
Desbalance de clases	10
Costo computacional y <code>cp</code>	11
Comparación cualitativa de jerarquías	11
Jerarquía integrada	11
Relación con la aplicación	11
Fuentes técnicas	13
Conclusiones y contradicciones resultantes	13

Jerarquías y dependencias entre hiperparámetros CART

Supuestos y consideraciones

Este análisis se refiere a `rpart` bajo los siguientes supuestos:

- árbol binario;
- observaciones indivisibles y con pesos unitarios;
- raíz situada en profundidad 0;
- `minspl` y `minbucket` expresados como números enteros de observaciones;
- ausencia de garantías sobre la existencia de cortes útiles en los predictores;
- distinción cualitativa entre N chico y N grande, sin imponer un umbral universal.

La separación entre N chico y N grande depende del problema. Un mismo tamaño puede ser grande desde el punto de vista computacional y pequeño para estimar eventos extremadamente infrecuentes.

Estado de la información

Las definiciones de `rpart` permiten establecer relaciones exactas de factibilidad entre `minsplit`, `minbucket`, `maxdepth` y N . No permiten deducir por sí solas los valores predictivamente óptimos.

La selección final también depende de:

- distribución y ruido de la respuesta;
- prevalencia de clases;
- estructura y cantidad de predictores;
- valores faltantes y divisiones sustitutas;
- parámetro de complejidad `cp`;
- esquema de validación;
- dependencia temporal, espacial o por grupos.

Contradicciones y precisiones previas

No se detectan contradicciones en las relaciones combinatorias centrales. Sí deben evitarse tres interpretaciones incorrectas:

1. 4 `minbucket` no es una cota máxima teórica para `minsplit`. La relación `minsplit/minbucket` entre 2 y 4 es sólo una región heurística alrededor del valor predeterminado de `rpart`.
2. La profundidad factible no es la profundidad que `rpart` necesariamente alcanza. Es únicamente una cota superior por tamaño de nodos.
3. Un N grande no implica que `minbucket` deba ser una fracción fija y grande de N . Ese escalamiento corresponde a macrosegmentación, no a una regla estadística universal.

Notación

Se utilizará:

- N : cantidad de observaciones disponibles para ajustar el árbol;
- m_s : `minsplit`;
- m_b : `minbucket`;
- M : valor configurado de `maxdepth`;
- D : profundidad objetivo;
- d_{real} : profundidad finalmente construida;
- cp : parámetro de complejidad;
- n : cantidad de observaciones en un nodo particular;
- $r = m_s/m_b$: relación entre los dos controles de tamaño;
- $q = m_b/N$: fracción mínima de observaciones por hoja.

Cuando existe remuestreo, N debe interpretarse como el tamaño efectivo del conjunto de entrenamiento. Para construir una única grilla válida en todos los folds conviene utilizar el menor N de entrenamiento.

Formalización de la factibilidad local

Para que `rpart` intente dividir un nodo debe cumplirse:

$$n \geq m_s.$$

Para que una división binaria pueda dejar dos hijos admisibles:

$$n_{\text{izq}} \geq m_b, \quad n_{\text{der}} \geq m_b.$$

Como $n = n_{\text{izq}} + n_{\text{der}}$, resulta necesario:

$$n \geq 2m_b.$$

El umbral combinado de tamaño para que una división sea materialmente posible es, por tanto:

$$T = \max(m_s, 2m_b).$$

La condición $n \geq T$ es necesaria desde el punto de vista combinatorio. No es suficiente para garantizar una división real: puede no existir un punto de corte válido o la mejora puede ser insuficiente para **cp**.

Regímenes de dominancia entre **minsplit** y **minbucket**

La relación

$$r = \frac{m_s}{m_b}$$

determina tres regímenes.

Régimen 1: $r < 2$

$$m_s < 2m_b \implies T = 2m_b.$$

minbucket domina la factibilidad local. **minsplit** es redundante respecto de la posibilidad material de dividir el nodo: cualquier nodo demasiado pequeño para producir dos hijos válidos seguirá siendo indivisible aunque supere **minsplit**.

Régimen 2: $r = 2$

$$m_s = 2m_b \implies T = m_s = 2m_b.$$

Ambas restricciones coinciden. Es el límite inferior no redundante para **minsplit**.

Régimen 3: $r > 2$

$$m_s > 2m_b \implies T = m_s.$$

minsplit domina el umbral para intentar la división. **minbucket** no deja de ser relevante: sigue regulando los tamaños de los hijos y el costo, en observaciones, de agregar profundidad.

No existe una razón combinatoria para imponer $r \leq 4$. Valores como $r = 6, 8, 10$ son válidos y representan una regularización más fuerte mediante **minsplit**.




Figura 1: Diagrama 1

Cota de profundidad factible

Para construir un camino raíz-hoja de profundidad $d \geq 1$, el último nodo que se divide debe contener al menos T observaciones. Cada uno de los $d - 1$ niveles anteriores debe dejar, fuera del camino principal, un hermano con al menos m_b observaciones.

El tamaño mínimo necesario es:

$$N_{\min}(d) = T + (d - 1)m_b.$$

La profundidad d es combinatoriamente factible si:

$$N \geq T + (d - 1)m_b.$$

Despejando:

$$d \leq \left\lfloor \frac{N - T}{m_b} \right\rfloor + 1.$$

La cota completa es:

$$d_{\text{fact}} = \begin{cases} 0, & N < T, \\ \left\lfloor \frac{N - T}{m_b} \right\rfloor + 1, & N \geq T. \end{cases}$$

`rpart` restringe `maxdepth` a 30. Si el usuario configura M , la profundidad estructural permitida queda:

$$d_{\text{lim}} = \min(M, 30, d_{\text{fact}}).$$

La profundidad realizada satisface:

$$d_{\text{real}} \leq d_{\text{lim}}.$$

La desigualdad puede ser estricta por `cp`, falta de cortes elegibles, decisiones greedy, empates, valores faltantes o ausencia de señal.

Restricciones para conservar una profundidad objetivo

Para que una profundidad D permanezca posible:

$$\max(m_s, 2m_b) + (D - 1)m_b \leq N.$$

Esto equivale a imponer simultáneamente:




Figura 2: Diagrama 2

$$m_s \leq N - (D - 1)m_b$$

y:

$$(D + 1)m_b \leq N.$$

Por tanto:

$$m_b \leq \left\lfloor \frac{N}{D + 1} \right\rfloor, \quad m_s \leq N - (D - 1)m_b.$$

Si además se eliminan valores redundantes de **minsplit**:

$$2m_b \leq m_s \leq N - (D - 1)m_b.$$

La cota superior correcta para **minsplit** depende de N , m_b y D . No es $4m_b$.

Número de hojas y profundidad balanceada

Toda hoja debe contener al menos m_b observaciones. En consecuencia, el número de hojas L está acotado por:

$$L \leq \left\lceil \frac{N}{m_b} \right\rceil.$$

Si el árbol fuese aproximadamente balanceado, una referencia para su profundidad sería:

$$d_{\text{bal}} \approx \log_2 \left(\frac{N}{m_b} \right).$$

Esta expresión no es una cota para caminos muy desbalanceados. La fórmula de d_{fact} es la cota relevante para el camino más profundo.

Jerarquía de hiperparámetros con N chico

En este régimen los conteos enteros y la escasez de observaciones dominan el problema. Una variación de una sola observación puede representar una fracción apreciable de N .

Orden de influencia típico

1. **minbucket**: controla la varianza de las estimaciones terminales, el número máximo de hojas y el costo de cada nivel adicional.
2. **minsplit**: se vuelve activo cuando $m_s > 2m_b$; con $m_s < 2m_b$ no modifica la factibilidad material.
3. **maxdepth**: puede resultar redundante si $d_{\text{fact}} < M$.
4. **cp**: puede detener el árbol antes, pero su estimación y su validación suelen presentar mayor incertidumbre por la muestra limitada.

Esta jerarquía no es absoluta. Un **cp** alto puede dominar cualquier restricción de tamaño y producir un árbol trivial.

Consecuencias prácticas

- Conviene explorar conteos absolutos pequeños y proporciones de N .
- Deben deduplicarse valores después del redondeo.
- Es especialmente importante verificar el menor tamaño de entrenamiento de los folds.
- La validación repetida es más informativa que una única partición.
- Hojas demasiado pequeñas producen estimaciones inestables.
- Porcentajes grandes de **minbucket** pueden hacer redundante **maxdepth**.

Ejemplo ilustrativo

Sea:

$$N = 1000, \quad m_b = 100, \quad m_s = 300.$$

Entonces:

$$T = 300,$$

$$d_{\text{fact}} = \left\lfloor \frac{1000 - 300}{100} \right\rfloor + 1 = 8.$$

Cualquier **maxdepth** mayor o igual que 8 es estructuralmente redundante. Además:

$$L \leq \left\lfloor \frac{1000}{100} \right\rfloor = 10.$$

En este ejemplo, `minbucket` y `minsplit` restringen el árbol antes que el límite máximo de 30.

Jerarquía de hiperparámetros con N grande

Con N grande debe distinguirse el tamaño absoluto de una hoja de su proporción respecto de la muestra. Mantener una proporción fija puede producir hojas con decenas o cientos de miles de observaciones.

La jerarquía depende del modo de escalamiento de `minbucket`.

Escalamiento lineal

Sea:

$$m_b = qN, \quad m_s = r m_b.$$

Entonces:

$$T = \max(r, 2)qN.$$

La profundidad factible es aproximadamente:

$$d_{\text{fact}} \approx \left\lfloor \frac{1 - \max(r, 2)q}{q} \right\rfloor + 1.$$

Para q y r fijos, esta cota no crece con N . También:

$$L \leq \left\lfloor \frac{1}{q} \right\rfloor.$$

Por ello, usar `minbucket`/N fijo define esencialmente una resolución de segmentación independiente del tamaño total. Es apropiado si se desean pocos segmentos grandes.

Escalamiento sublineal

Considérese:

$$m_b = cN^\alpha, \quad m_s = r m_b, \quad 0 < \alpha < 1.$$

Entonces:

$$\frac{m_b}{N} = cN^{\alpha-1} \longrightarrow 0$$

y:

$$d_{\text{fact}} \approx \frac{N^{1-\alpha}}{c} - \max(r, 2) + 1.$$

La elección heurística $\alpha = 1/2$ produce:

$$m_b = c\sqrt{N}.$$

Este régimen hace crecer el tamaño absoluto de las hojas mientras reduce su fracción relativa. No garantiza optimalidad, pero evita que una proporción fija congele el número máximo de hojas.

Escalamiento absoluto

Si m_b permanece constante mientras N aumenta:

$$\frac{m_b}{N} \rightarrow 0$$

y la cota de profundidad crece aproximadamente de forma lineal con N . En ese caso `maxdepth` y `cp` suelen convertirse en los controles efectivos de complejidad. Mantener hojas absolutas demasiado pequeñas puede incrementar la varianza y el costo computacional.

Orden de influencia típico

Con escalamiento lineal:

1. `minbucket` domina la resolución y el número de hojas;
2. `minsplit` regula qué nodos pueden continuar;
3. `maxdepth` domina sólo si se fija por debajo de la cota inducida por los tamaños;
4. `cp` determina qué divisiones sobreviven al criterio de mejora.

Con escalamiento absoluto o sublineal:

1. `maxdepth` y `cp` suelen dominar la profundidad realizada;
2. `minbucket` regula estabilidad terminal y número potencial de hojas;
3. `minsplit` actúa como compuerta estructural y computacional;
4. el costo de buscar cortes puede justificar relaciones $r > 4$.

Ejemplo de macrosegmentación

Sea:

$$N = 1\,000\,000, \quad m_b = 0.05N = 50\,000, \quad m_s = 3m_b = 150\,000.$$

Entonces:

$$d_{\text{fact}} = \left\lfloor \frac{1\,000\,000 - 150\,000}{50\,000} \right\rfloor + 1 = 18$$

y:

$$L \leq 20.$$

El tamaño masivo de la muestra no genera alta resolución: la proporción fija limita el árbol a un máximo de 20 hojas.

Ejemplo de escalamiento sublineal

Para el mismo N , tomando:

$$m_b = \sqrt{N} = 1000, \quad m_s = 3m_b = 3000,$$

se obtiene:

$$d_{\text{fact}} = \left\lfloor \frac{1\,000\,000 - 3000}{1000} \right\rfloor + 1 = 998.$$

En `rpart`, el límite 30 pasa a ser activo. Si se configura `maxdepth = 12`, entonces:

$$d_{\text{lim}} = 12.$$

En este caso `maxdepth` o `cp`, y no la factibilidad por tamaño, determinan la profundidad efectiva.

Desbalance de clases

Si la clase de interés tiene prevalencia p y se desea una cantidad esperada mínima de k casos positivos por hoja, una referencia inicial es:

$$m_b \geq \frac{k}{p}.$$

Por ejemplo, con:

$$p = 0.001, \quad k = 20,$$

resulta:

$$m_b \geq 20\,000.$$

Esta relación supone mezcla aproximadamente aleatoria dentro de las hojas. No garantiza que cada hoja contenga k positivos, pero muestra por qué un `minbucket` aparentemente grande puede ser necesario incluso con millones de observaciones.

Costo computacional y cp

La factibilidad estructural no representa el costo completo:

- reducir `minbucket` aumenta el número potencial de nodos y hojas;
- reducir `minsplit` aumenta la cantidad de nodos en los que se buscan cortes;
- aumentar `maxdepth` habilita búsquedas en niveles adicionales;
- reducir `cp` permite perseguir mejoras más pequeñas;
- aumentar el número de predictores incrementa la búsqueda de cortes y divisiones competidoras;
- divisiones sustitutas pueden representar una parte sustancial del costo.

En N grande, `minsplit` puede utilizarse como control computacional con $r > 4$. Esta decisión sacrifica divisiones potencialmente válidas para evitar evaluarlas en nodos pequeños.

Comparación cualitativa de jerarquías

Jerarquía integrada

La interpretación correcta requiere recorrer cuatro niveles:

1. **Factibilidad local:**

$$T = \max(m_s, 2m_b).$$

2. **Factibilidad global de profundidad:**

$$d_{\text{fact}} = \left\lfloor \frac{N - T}{m_b} \right\rfloor + 1.$$

Esta expresión corresponde a $N \geq T$; si $N < T$, la profundidad factible es 0.

3. **Límite configurado:**

$$d_{\text{lim}} = \min(M, 30, d_{\text{fact}}).$$

4. **Árbol realizado:** resultado de `cp`, cortes disponibles, datos faltantes, criterio greedy y posterior selección mediante validación.

Ningún nivel posterior puede recuperar estructuras descartadas por un nivel anterior.

Relación con la aplicación

Para las combinaciones con $T \leq N$, la aplicación implementa correctamente:

$$T = \max(m_s, 2m_b)$$

y:

$$d_{\text{max}} = \min \left(30, \left\lfloor \frac{N - T}{m_b} \right\rfloor + 1 \right).$$

Las combinaciones con $T > N$ se descartan antes de esa asignación.

La grilla recomendada actual utiliza:





Figura 3: Diagrama 3

$$\frac{m_b}{N} \in \{0.005, 0.01, 0.02, 0.05, 0.10\}$$

y:

$$\frac{m_s}{m_b} \in \{2, 3, 4\}.$$

Estas elecciones son heurísticas:

- las proporciones de `minbucket` representan una búsqueda de segmentación proporcional;
- la relación 3 reproduce el centro definido por el valor predeterminado de `rpart`;
- las relaciones 2 y 4 exploran configuraciones próximas;
- el modo manual permite utilizar $r > 4$ y escalas absolutas o sublineales;
- excluir $m_s < 2m_b$ elimina redundancia combinatoria, no modelos estadísticamente demostrados como inferiores.

Para N grande, la grilla proporcional debe interpretarse como modo de macrosegmentación. Una búsqueda predictiva de mayor resolución debería compararla con escalas absolutas o sublineales.

Fuentes técnicas

- Documentación de `rpart.control`: <https://rdrr.io/cran/rpart/man/rpart.control.html>
- Código fuente de `rpart.control`: <https://github.com/cran/rpart/blob/master/R/rpart.control.R>
- Rutina de particionamiento de `rpart`: <https://github.com/cran/rpart/blob/master/src/partition.c>

Conclusiones y contradicciones resultantes

La jerarquía no depende únicamente de si N es chico o grande. Depende de cómo escalan m_b y m_s respecto de N .

- Con N chico, los conteos mínimos suelen imponer la restricción principal.
- Con N grande y escalamiento lineal, `minbucket` conserva una resolución fija y domina el número de hojas.
- Con N grande y escalamiento sublineal o absoluto, `maxdepth` y `cp` adquieren mayor predominio.
- `minsplit` es redundante si $m_s < 2m_b$, coincide con `minbucket` cuando $m_s = 2m_b$ y domina el umbral local cuando $m_s > 2m_b$.
- $4m_b$ no es una cota teórica para `minsplit`.

No se genera una contradicción lógica entre los regímenes: las diferencias surgen de distintas funciones de escalamiento. La única conclusión que no puede obtenerse de estas fórmulas es cuál combinación maximiza el rendimiento predictivo; esa decisión requiere validación sobre el problema concreto.